



HW3 Report

2024010729 刘武韬



1.Tfmr_scratch & Tfmr_finetime

Tfmr_scratch 与 Tfmr_finetime均采用默认模型和训练超参进行训练，损失率与Perplexity曲线如下

Tfmr_scratch



Tfmr_finetune



两模型经六轮训练后均早停，从最终loss与perplexity来看，Tfmr_finetune模型loss在训练集上降到2.2以下，有效集上降到3.0以下，perplexity降到20以下，训练效果明显优于Tfmr_finetune模型，可以看出在预训练基础上进行finetuning后模型训练效果会更好。

以下是二者在测试集上的表现，这里默认取temperature=1.0，解码模式为random

	Perplexity	Forward BLEU	Backward BLEU	Harmonic BLEU
Tfmr_scratch	18.59	0.317	0.446	0.371
Tfmr_finetune	15.53	0.400	0.467	0.431

从结果很容易看出Tfmr_finetune模型在测试集上表现也更好。

2.Temprature & Top-p

我在两模型上选取不同预测温度与Nucleus采样分别进行四组实验，实验设置和结果表格如下

Tfmr_scratch

Hyperparameters	Perplexity	Forward BLEU	Backward BLEU	Harmonic BLEU
random, temperature=1.0	18.59	0.317	0.446	0.371
random, temperature=0.7	18.59	0.448	0.366	0.403
top-p=0.9, temperature=1.0	18.59	0.384	0.346	0.364
top-p=0.9, temperature=0.7	18.59	0.479	0.235	0.315

Tfmr_finetune

Hyperparameters	Perplexity	Forward BLEU	Backward BLEU	Harmonic BLEU
random, temperature=1.0	15.53	0.400	0.467	0.431
random, temperature=0.7	15.53	0.530	0.434	0.478
top-p=0.9, temperature=1.0	15.53	0.470	0.466	0.468
top-p=0.9, temperature=0.7	15.53	0.560	0.363	0.441

同样条件下，更高的预测温度会使得预测概率分布变得平缓，生成时更有可能采样到更多的单词，而低温使得分布差距拉大，使得预测结果变得更确定，生成文本更加流畅。而top-p让模型无法采样到低频的无意义词，能在有效控制文本的多样性。

从训练结果可知，预测温度更高会使前向BLEU降低，后向BLEU增大，也正是意味着生成文本的流畅度降低，而多样性增大；top-p的限制则会一定程度上使得文本更加流畅，前向BLEU表现更好，但同时也会一定程度上限制文本的创造性，使得后向BLEU降低。

从Harmonic BLEU的综合结果来看，表现最好的是温度0.7&随机采样的finetune模型。

3.生成文本质量

以下展示各模型在最优参数配置下生成的示例文本。

Tfmr_finetune_random_temprature1.0

- 1.A person sitting on a bench in the shade of tree . . . benches are being watched . In the distance .
- 2.A small giraffe laying on top of a lush green field . In the background . There is a street sign , with the door .
- 3.A woman is holding a baby and two baby sheep . The sheep are sitting on the ground .
- 4.A bench is shown in the middle of the woods . There is bright enough for us to see . The book shelf and the car are looking at the distance . There are several
- 5.A white and red fire hydrant sitting on a grassy hillside .
- 6.A photo taken of a giraffe that is standing in the grass . While people are walking by the fence . .
- 7.A couple of giraffe standing next to each other on a lush green field . In a zoo exhibit .
- 8.A man who is sitting on a bench near a beach . There is a dog is drinking from the water . There is a small car and a fire hydrant .
- 9.A wooden bench sitting in the middle of a park . The man is walking through the water . There is plenty of flowers in the forest . The benches
- 10.The city bus is traveling down the street at night . There is a traffic light . There is standing on the street . There is a few people riding on the street . One

Tfmr_scratch_random_temprature0.7

- 1.A man sitting on a bench in a park holding a bunch of brown . . S . . of sheep . Air Force .as . of benches . Air people . Air green
- 2.Two giraffes standing in the middle of a grass field . above boats .ers . than the trees . of the grassy area at a trees . to a garden .
- 3.The woman is sitting on her bench next to a dog . ambulance .melon . up . to them . for the map . into the sheep . S .ons .
- 4.A bus driving down a city street in the rain . is shown . towards the trees . . up . with a one of a red . of corner .ored - S .
- 5.A large jetliner flying over a cloudy sky with snow . Air Force . airliner flies . . over it .over . open together . of air . S . Air Force jets
- 6.A herd of sheep grazing together in a grassy field .es . .ut . over a field . . of sheep eating grass . . . of grass .es .as
- 7.A pole that is on the side of a road . S . S . time . time . to a plane . with people on it . of a city so it . abandoned
- 8.A wooden bench sitting in the middle of a grassy area .ed area . with trees . up . for a tree . up . . of water . S . S .
- 9.A traffic light is coming in for a turn to see . over a city . for a photo . at night time . of if . for a pair of buses . - cart
- 10.A black cat sitting on the bench in a park .roller .as . A is standing . to another sheep . of a cage . the grass . up . together . for

两模型的常见错误包括冠词缺失、主谓不一致与标点滥用。Tfmr_finetune能生成语义连贯、结构完整的句子，尽管存在少量语法错误，但整体语义一致性良好；相比之下，Tfmr_scratch生成的句子往往在前半部分较

为流畅，而在后半部分出现语义混乱与标点误用等问题。

总体而言，两模型生成质量与 BLEU / Perplexity 指标趋势一致：Tfmr_finetune_random_temperature=0.7生成结果最为自然，具有更强的生成能力与语言一致性。

4.Normalization Strategy

PostNorm实现

```
# TfmrBlock forward方法
    residual = hidden_states
    attn_outputs = self.attn(
        hidden_states,
        layer_past=layer_past,
        use_cache=use_cache,
    )
    attn_output = attn_outputs[0]
    outputs = attn_outputs[1:]
    hidden_states = self.ln_1(attn_output + residual)
    residual = hidden_states
    feed_forward_hidden_states = self.mlp(hidden_states)
    hidden_states = self.ln_2(residual + feed_forward_hidden_states)
```

RMSNorm实现

```
class RMSNorm(nn.Module):
    def __init__(self, hidden_size, eps=1e-8):
        super().__init__()
        self.eps = eps
        self.weight = nn.Parameter(torch.ones(hidden_size))

    def forward(self, x):
        rms = x.pow(2).mean(dim=-1, keepdim=True).add(self.eps).sqrt()
        x_norm = x / rms
        return x_norm * self.weight
```

这里我分别选取PostNorm与RMSNorm再进行了两组实验，超参选取之前scratch模型表现最好的温度0.7与random采样。测试结果如下。

Norm Strategy	Perplexity	Forward BLEU	Backward BLEU	Harmonic BLEU
PreNorm	18.59	0.448	0.366	0.403
PostNorm	17.99	0.471	0.388	0.426
Pre-RMSNorm	18.64	0.446	0.403	0.424

从结果可以看出，三者生成表现基本相近。PreNorm的结构能在训练过程中能更好保证梯度分布，防止深层的梯度消失，可是因为该模型仅包含三层Attention Block，无需计算深层梯度，这点优势并未体现；反而相较

PostNorm结构在最终输出时缺少归一化操作，输出分布不均，进而导致了模型表现效果不好。

而RMSNorm不需要计算均值，计算复杂度会更小，使模型在训练中更快收敛，也能保证梯度稳定支持深层训练，且在浅层结构中表现稳定。

5.Network architecture and Hyperparameters with Best Performance

经多组实验后生成表现最好的结果与模型架构与超参如下，生成结果见output.txt

Perplexity	Forward BLEU	Backward BLEU	Harmonic BLEU
15.53	0.530	0.434	0.478

```
# Training Hyperparameterse
(random, temperature=0.7, lr=10-4, batch_size=32, epoches=20, maxlen=35)
# Tfmr_finetue
TfmrLMHeadModel(
  (transformer): TfmrModel(
    (wte): Embedding(50257, 768)
    (wpe): Embedding(1024, 768)
    (drop): Dropout(p=0.1, inplace=False)
    (h): ModuleList(
      (0-2): 3 x TfmrBlock(
        (ln_1): LayerNorm((768,)), eps=1e-05, elementwise_affine=True)
        (attn): TfmrAttention(
          (c_attn): TransposeLinear()
          (c_proj): TransposeLinear()
          (attn_dropout): Dropout(p=0.1, inplace=False)
          (resid_dropout): Dropout(p=0.1, inplace=False)
        )
        (ln_2): LayerNorm((768,)), eps=1e-05, elementwise_affine=True)
        (mlp): TfmrMLP(
          (c_fc): TransposeLinear()
          (c_proj): TransposeLinear()
          (dropout): Dropout(p=0.1, inplace=False)
        )
      )
    )
    (ln_f): LayerNorm((768,)), eps=1e-05, elementwise_affine=True)
  )
  (lm_head): Linear(in_features=768, out_features=50257, bias=False)
)
```

6, Transformer Decoder

Transformer & RNN

1.时间与空间复杂度

RNN 需要逐时间步递归计算，每步依赖前一步的隐藏状态，时间复杂度为 $O(TD^2)$ 无法并行；Transformer 采用全局注意力机制，一次性计算所有位置间的依赖，时间复杂度为 $O(T^2D)$ 但可以完全并行化，GPU 计算

效率更高。在空间复杂度上，RNN 仅需存储每个时间步的隐藏状态，而 Transformer 需要保存整个注意力矩阵 $O(T \times T)$ 显存占用更高。

2.性能与建模能力

Transformer的自注意力机制能捕获任意距离的依赖，而RNN由于梯度消失或爆炸，长程依赖建模能力较弱。因此Transformer的多头注意力可以在不同子空间同时学习多层语义关系，生成效果与收敛速度均显著优于RNN。

3.位置信息表示

RNN的结构天然包含序列顺序，而Transformer不具备时序递归特性，因此需通过位置编码显式使用可学习的位置嵌入，使模型在训练过程中自动学习最优的位置表示。

Inference

1.use_cache参数

在推理（生成）阶段，use_cache用于缓存每层的key和value，每次仅需计算当前步的注意力，与历史缓存拼接，避免在生成每个新 token 时重新计算全部历史信息，降低推理时间。

2.推理阶段时间复杂度计算

在每一个block计算第t个token时，模型在自注意力层的需要计算前t-1个token的隐状态，时间复杂度为 $O(tNd)$ ，而在FFN层时间复杂度为 $O(4d^2)$ ，因此经历B个block计算后时间复杂度为 $O(B \times (tNd + 4d^2))$ 。对于整个序列则需要 $O(B \times (NdT + 4d^2 \times T))$ 的时间复杂度。

在use_cache为true时，每步计算可以缓存前缀token的key与value，时间复杂度可以降为 $O(B \times (NdT + 4d^2 \times T))$ 。

3.主导项

当序列较短 (T 较小)，隐藏维度较大时，FFN的计算量更大，是主要瓶颈。当序列较长 (T 较大) 时，自注意力的复杂度（不使用缓存）快速增长，成为主要计算开销。因此，短文本任务中前馈层主导，长文本生成中注意力层主导。

Pretraining

在本实验中，使用预训练权重初始化的Tfmr_finetune模型在困惑度、收敛速度及BLEU指标上均显著优于从零训练的Tfmr_scratch模型。

预训练模型能够提供通用的语言表示，使微调过程收敛更快，生成文本更自然、语法更流畅。其困惑度从18.59降至 15.53，Forward BLEU提升约25%，说明模型更好地掌握了语义结构与词汇分布；而在生成过程中，finetune模型更容易生成连贯的句子，避免语义重复或逻辑跳跃，符合预期结果。

因此，预训练显著提高了Transformer Decoder的生成能力与稳定性，验证了预训练-微调范式在文本生成任务中的有效性。